Reto - Entrega 2

Maestría en Inteligencia Artificial Aplicada

Curso: Inteligencia Artificial y Aprendizaje Automático

Tecnológico de Monterrey

Prof: María de la Paz Rico Fernández

Genaro Ramos Higuera - A00351269

Gerardo Aaron Castañeda Jaramillo - A01137646


```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

from sklearn.preprocessing import OneHotEncoder
from sklearn.ensemble import RandomForestClassifier
from sklearn.tree import DecisionTreeClassifier
from sklearn.inspection import permutation_importance
from sklearn.model_selection import train_test_split
from sklearn import metrics
from sklearn.metrics import accuracy_score, f1_score, precision_score, recall_score
from sklearn.model_selection import RepeatedStratifiedKFold, cross_validate, StratifiedKFold
from sklearn.model_selection import GridSearchCV
from sklearn.metrics import get_scorer
from sklearn.metrics import confusion_matrix

from sklearn.model_selection import learning_curve
from sklearn.model_selection import validation_curve

from sklearn.metrics import classification_report
from sklearn.metrics import RocCurveDisplay, precision_recall_curve, roc_curve
```

AGUAS SUBTERRANEAS

```
url = 'https://github.com/PosgradoMNA/actividades-del-projecto-equipo-52/blob/main/aguas_subt

data_asb = pd.read_csv(url,sep=",")
```

```
print(data_asb.shape)
data_asb.head()
```

```
(1054, 34)
```

	CLAVE	LONGITUD	LATITUD	ORGANISMO_DE_CUENCA	SUBTIPO	ALC_mg/L	COND_mS/cm
0	DLAGU6	-102.02210	22.20887	6.0	5.0	229.990	940.0
1	DLAGU6516	-102.20075	21.99958	6.0	5.0	231.990	608.0
2	DLAGU7	-102.28801	22.36685	6.0	5.0	204.920	532.0
3	DLAGU9	-102.29449	22.18435	6.0	5.0	327.000	686.0
4	DLBAJ107	-110.24480	23.45138	10.0	5.0	309.885	1841.0

5 rows × 34 columns

Selecciona tus variables independientes X y dependiente Y (semáforo)

Separamos las columnas en base a su tipo de variable:

```
#definimos variables numéricas #16
num_nom_geo = ['LONGITUD','LATITUD']
num_nom_cal = ['ALC_mg/L','COND_mS/cm','SDT_M_mg/L','FLUO_mg/L','DUR_mg/L','CF_NMP/100_mL','N
               'HG_TOT_mg/L','PB_TOT_mg/L','MN_TOT_mg/L','FE_TOT_mg/L']
#definimos variables categóricas #16
cat_nom = ['ORGANISMO_DE_CUENCA','SUBTIPO']
cat_nom_cal = ['CALIDAD_ALC','CALIDAD_COND','CALIDAD_SDT','CALIDAD_FLUO','CALIDAD_DUR', 'CALI
               'CALIDAD_CD','CALIDAD_CR','CALIDAD_HG','CALIDAD_PB','CALIDAD_MN','CALIDAD_FE']
#VARIABLE CATEGORICA DE SALIDA Y  #1
y_nom = ['SEMAFORO']
```

Generamos los datos en Y, y dos tipos de X. Una donde se utilizarán los datos numéricos de calidad, y otra donde se utilizarán los datos categóricos de calidad. Utilizar las variables numéricas y categorías de calidad, donde las categóricas son dependientes de las numéricas, puede afectar la correlación entre variables y eventualmente el modelo.

```
Y = data_asb[['SEMAFORO']]

X_num = data_asb[num_nom_geo + cat_nom + num_nom_cal]
X_cat = data_asb[num_nom_geo + cat_nom + cat_nom_cal]
```

Cambia a label encoding el semáforo, ej, de ["clase 1", "clase 2", "clase 3"] a [1,2,3]

Previamente en la parte 1 del reto ya se cambiaron los valores del semáforo a 1:verde, 2:amarillo, 3:rojo

```
Y.value_counts()
```

```
SEMAFORO
1           427
3           382
2           245
dtype: int64
```

Realiza un análisis general de las features importances a traves de decision trees o random forest.

Definimos modelos a usar:

```
def get_models():
  modelos = list()
  nombres = list()

  modelos.append(DecisionTreeClassifier())
  nombres.append('DTC')

  modelos.append(RandomForestClassifier())
  nombres.append('RFC')

  return modelos, nombres
```

Obtenemos los feature importance con variables de calidad numéricas:

```
modelos, nombres = get_models()

for m in range(len(modelos)):
  modelos[m].fit(X_num, np.ravel(Y))
  importance = permutation_importance(modelos[m], X_num, Y, n_repeats=10)
  print('\033[1m' + nombres[m] + '\033[0m')
  for i,v in enumerate(importance['importances_mean']):
    print(X_num.columns[i]+':', v.round(3))
  f = plt.figure()
  plt.bar(X_num.columns, importance['importances_mean'])
  plt.xticks(rotation='vertical')
  plt.show()
```

DTC

LONGITUD: 0.002
LATITUD: 0.006
ORGANISMO_DE_CUENCA: 0.0
SUBTIPO: 0.0
ALC_mg/L: 0.029
COND_mS/cm: 0.059
SDT_M_mg/L: 0.012
FLUO_mg/L: 0.198
DUR_mg/L: 0.161
CF_NMP/100_mL: 0.08
NNO3_mg/L: 0.1
AS_TOT_mg/L: 0.116
CD_TOT_mg/L: 0.0
CR_TOT_mg/L: 0.018
HG_TOT_mg/L: 0.0
PB_TOT_mg/L: 0.015
MN_TOT_mg/L: 0.056
FE_TOT_mg/L: 0.08

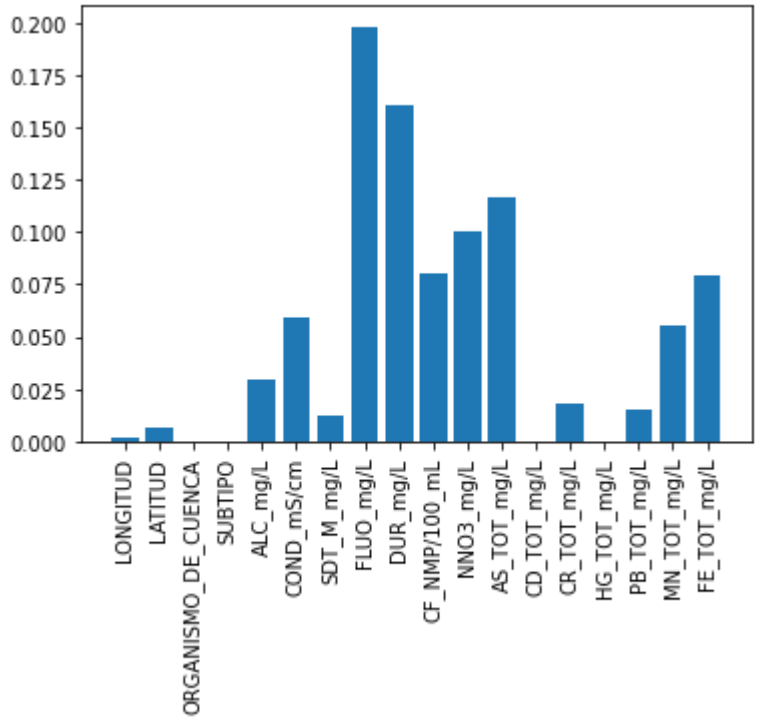

RFC

LONGITUD: 0.0
LATITUD: 0.002
ORGANISMO_DE_CUENCA: 0.0
SUBTIPO: 0.0
ALC_mg/L: 0.026
COND_mS/cm: 0.008
SDT_M_mg/L: 0.009
FLUO_mg/L: 0.196
DUR_mg/L: 0.137
CF_NMP/100_mL: 0.075
NNO3_mg/L: 0.095
AS_TOT_mg/L: 0.115
CD_TOT_mg/L: 0.0
CR_TOT_mg/L: 0.009
HG_TOT_mg/L: 0.0

```
PB_TOT_mg/L: 0.006
MN_TOT_mg/L: 0.052
FE_TOT_mg/L: 0.078
```

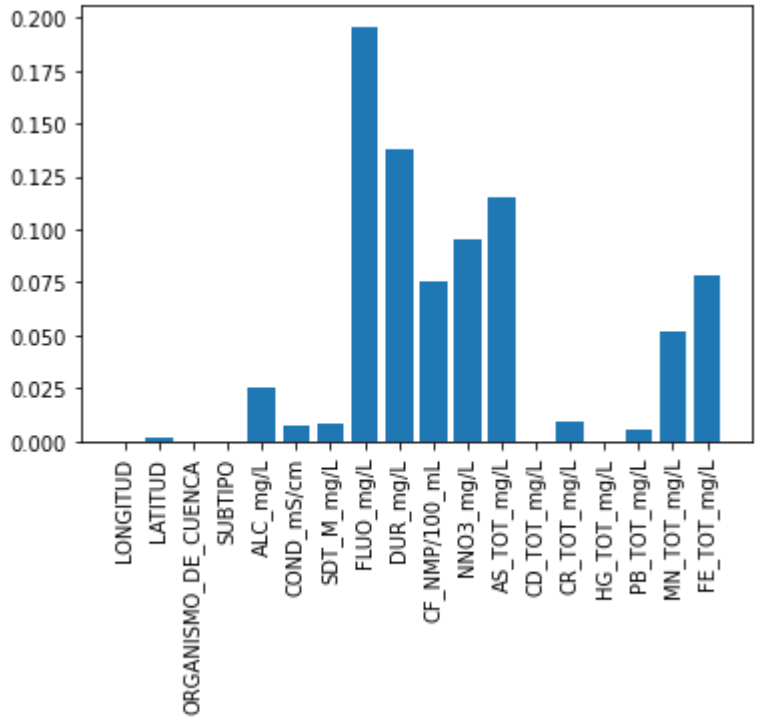

Obtenemos los feature importance con las variables de calidad categóricas:

```
modelos, nombres = get_models()

for m in range(len(modelos)):
  modelos[m].fit(X_cat, np.ravel(Y))
  importance = permutation_importance(modelos[m], X_cat, Y, n_repeats=10)
  print('\033[1m' + nombres[m] + '\033[0m')
  for i,v in enumerate(importance['importances_mean']):
    print(X_cat.columns[i]+':', v.round(3))
  f = plt.figure()
  plt.bar(X_cat.columns, importance['importances_mean'])
  plt.xticks(rotation='vertical')
  plt.show()
```

DTC

LONGITUD: 0.004
LATITUD: 0.009
ORGANISMO_DE_CUENCA: 0.0
SUBTIPO: 0.0
CALIDAD_ALC: 0.034
CALIDAD_COND: 0.058
CALIDAD_SDT: 0.006
CALIDAD_FLUO: 0.202
CALIDAD_DUR: 0.155
CALIDAD_CF: 0.077
CALIDAD_NNO3: 0.101
CALIDAD_AS: 0.112
CALIDAD_CD: 0.0
CALIDAD_CR: 0.019
CALIDAD_HG: 0.0
CALIDAD_PB: 0.013
CALIDAD_MN: 0.057
CALIDAD_FE: 0.082

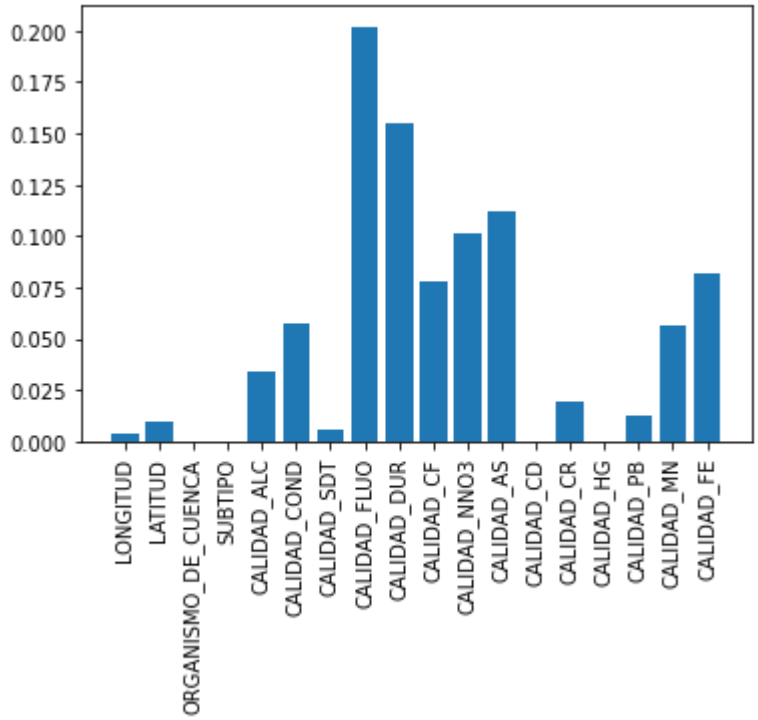

RFC

LONGITUD: 0.001
LATITUD: 0.002
ORGANISMO_DE_CUENCA: 0.0
SUBTIPO: 0.0
CALIDAD_ALC: 0.025
CALIDAD_COND: 0.011
CALIDAD_SDT: 0.011
CALIDAD_FLUO: 0.202
CALIDAD_DUR: 0.142
CALIDAD_CF: 0.077
CALIDAD_NNO3: 0.098
CALIDAD_AS: 0.11
CALIDAD_CD: 0.0
CALIDAD_CR: 0.017
CALIDAD_HG: 0.0

```
CALIDAD_PB: 0.008
CALIDAD_MN: 0.054
CALIDAD_FE: 0.073
```

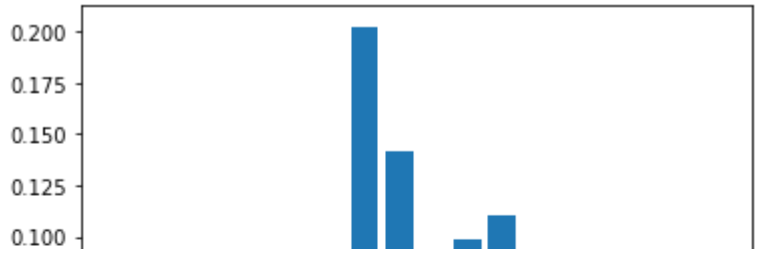

Y donde observamos que las variables de ubicación geográfica, así como organismo de cuenca y subtipo no tienen ninguna importancia significativa. Mientras que las de calidad, con algunas excepciones como las de CD y HG, son las que tienen mayor importancia.

Selecciona las variables de mayor importancia.

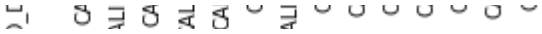

Removemos de nuestras listas de columnas las variables que no tienen feature importance

```
num_nom_cal.remove('CD_TOT_mg/L')
num_nom_cal.remove('HG_TOT_mg/L')
cat_nom_cal.remove('CALIDAD_CD')
cat_nom_cal.remove('CALIDAD_HG')
```

Observamos con cuales nos quedamos:

```
print(num_nom_cal)
print(cat_nom_cal)
```

```
['ALC_mg/L', 'COND_mS/cm', 'SDT_M_mg/L', 'FLUO_mg/L', 'DUR_mg/L', 'CF_NMP/100_mL', 'NNO3
['CALIDAD_ALC', 'CALIDAD_COND', 'CALIDAD_SDT', 'CALIDAD_FLUO', 'CALIDAD_DUR', 'CALIDAD_C
```

Generamos nuevas dataframes con las columnas a utilizar:

```
X_num = data_asb[num_nom_cal]
X_cat = data_asb[cat_nom_cal]
```

Realiza tu clasificador, recuerda dividir los datos de manera balanceada (auxiliate de train test split)

- Comenzamos con variables numéricas:

```
score_list = list()
grid_splits = list()


def get_scores(yreal, ypred, model, aver='micro'):
  temp_list = list()

  temp_list.append(model)
  accu = accuracy_score(yreal,ypred)
  f1 = f1_score(yreal,ypred,average=aver)
  precision = precision_score(yreal,ypred,average=aver)
  recall = recall_score(yreal,ypred,average=aver)

  temp_list.append(accu)
  temp_list.append(f1)
  temp_list.append(precision)
  temp_list.append(recall)
  print('Accuracy:', accu)
  print('f1_score:', f1)
  print('Precision:', precision)
  print('Recall:', recall)

  return temp_list
```

Sabemos de la parte 1 que las clases de salida tienen diferentes proporciones, por lo que utilizamos el parámetro stratify:

```
Xtv_num, Xtest_num, ytv_num, ytest_num = train_test_split(X_num, Y, test_size=0.15, stratify=
print(Xtv_num.shape, ': dimensión de datos de entrada de entrenamiento y validación')
print(Xtest_num.shape, ': dimensión de datos de entrada de prueba')
print(ytv_num.shape, ': dimensión de variable de salida para entrenamiento y validación')
print(ytest_num.shape, ': dimensión de variable de salida para prueba')
```

```
(895, 12) : dimensión de datos de entrada de entrenamiento y validación
(159, 12) : dimensión de datos de entrada de prueba
(895, 1) : dimensión de variable de salida para entrenamiento y validación
(159, 1) : dimensión de variable de salida para prueba
```

Decision Tree variables numéricas de calidad de entrada:

Comenzamos viendo la curva de aprendizaje para el parámetro de max_depth:

```
#obtenemos el modelo y los parametros de cross validation
modeloVC = DecisionTreeClassifier()
cvVC = RepeatedStratifiedKFold(n_splits=5, n_repeats=3, random_state=1)
```

```
delta_max_depth = np.linspace(1, 20, 20)

train_scores, valid_scores = validation_curve(modeloVC,
                                              Xtv_num,
                                              np.ravel(ytv_num),
                                              param_name="max_depth",
                                              param_range=delta_max_depth,
                                              cv=cvVC,
                                              scoring='accuracy')

train_mean = np.mean(train_scores, axis=1)
train_std = np.std(train_scores, axis=1)
valid_mean = np.mean(valid_scores, axis=1)
valid_std = np.std(valid_scores, axis=1)

# Curva de entrenamiento con la métrica de exactitud (accuracy):
plt.plot(delta_max_depth, train_mean, color='blue', marker='o', markersize=5, label='Training

# Curva de validación:
plt.plot(delta_max_depth, valid_mean, color='red', marker='o', markersize=5, label='Validatio

plt.title('Función validation_curve() para Decision Tree')
plt.xlabel('Valores del parámetro max_depth')
plt.ylabel('Accuracy')
plt.grid(b=True)
plt.legend(loc='lower right')
plt.show()
```

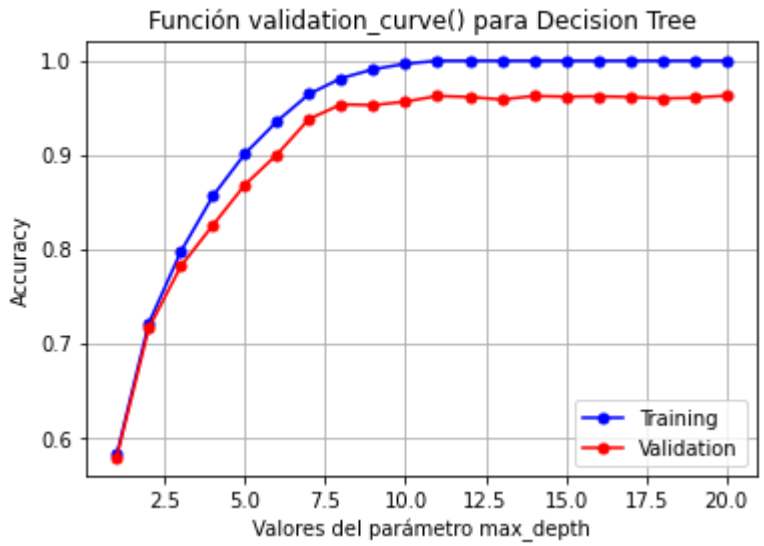

Y observamos que después de max_depth= 11 ya no existen cambios significativos para las curvas de training o validación, asi que nos quedamos con un máximo de 11 para el gridsearch para este parámetro y un minimo de 3 que donde la curva está cerca el 80% de accuracy.

```
#obtenemos el modelo y los parámetros
modeloDTC_iter = DecisionTreeClassifier()
cvSVM = RepeatedStratifiedKFold(n_splits=5, n_repeats=3, random_state=1)

dicc_grid = [{'ccp_alpha':[0.0001,0.01,0.1,1.0,10.,100],'criterion':['gini','entropy'],
              'max_depth':[3,4,5,6,7,8,9,10,11],'min_samples_split':[2,3,4,5,6],'class_weight'

grid1 = GridSearchCV(estimator=modeloDTC_iter,
                     param_grid=dicc_grid,
                     cv=cvSVM,
                     scoring='accuracy',
                     n_jobs=-1,
                     error_score='raise')
```

Corremos el grid search:

```
grid1.fit(Xtv_num, np.ravel(ytv_num))

print('Mejor valor de accuracy obtenido con la mejor combinación:', grid1.best_score_)
print('Mejor combinación de valores encontrados de los hiperparámetros:', grid1.best_params_)
print('Métrica utilizada:', grid1.scoring)
print('Mejor Index:',grid1.best_index_)

grid_splits.append(grid1)
```

```
Mejor valor de accuracy obtenido con la mejor combinación: 0.9627560521415269
Mejor combinación de valores encontrados de los hiperparámetros: {'ccp_alpha': 0.0001,
Métrica utilizada: accuracy
Mejor Index: 119
```

Observamos un accuracy del 96.27% máximo con los hiper parámetros. Ahora probamos el modelo con sus hiper parámetros para los datos de prueba:

```
model_DTC_num = DecisionTreeClassifier(**grid1.best_params_)

model_DTC_num.fit(Xtv_num, ytv_num)
#realizamos las predicciones
yhat_num = model_DTC_num.predict(Xtest_num)

score_list.append(get_scores(ytest_num,yhat_num, 'DTC num'))
```

```
Accuracy: 0.9622641509433962
f1_score: 0.9622641509433962
Precision: 0.9622641509433962
Recall: 0.9622641509433962
```

Donde observamos que accuracy disminuye cerca de 0.05%. Lo que sugiere que el modelo está prediciendo bien. Es un valor muy aceptable.

Random Forest variables numéricas de calidad de entrada:

Comenzamos viendo la curva de aprendizaje para el parámetro de max_depth:

```
#obtenemos el modelo y los parametros de cross validation
modeloVC = RandomForestClassifier()
cvVC = RepeatedStratifiedKFold(n_splits=5, n_repeats=3, random_state=1)

delta_max_depth = np.linspace(1, 20, 20)

train_scores, valid_scores = validation_curve(modeloVC,
                                              Xtv_num,
                                              np.ravel(ytv_num),
                                              param_name="max_depth",
                                              param_range=delta_max_depth,
                                              cv=cvVC,
                                              scoring='accuracy')

train_mean = np.mean(train_scores, axis=1)
train_std = np.std(train_scores, axis=1)
valid_mean = np.mean(valid_scores, axis=1)
valid_std = np.std(valid_scores, axis=1)

# Curva de entrenamiento con la métrica de exactitud (accuracy):
plt.plot(delta_max_depth, train_mean, color='blue', marker='o', markersize=5, label='Training

# Curva de validación:
plt.plot(delta_max_depth, valid_mean, color='red', marker='o', markersize=5, label='Validatio

plt.title('Función validation_curve() para Random Forest')
plt.xlabel('Valores del parámetro max_depth')
plt.ylabel('Accuracy')
plt.grid(b=True)
plt.legend(loc='lower right')
plt.show()
```

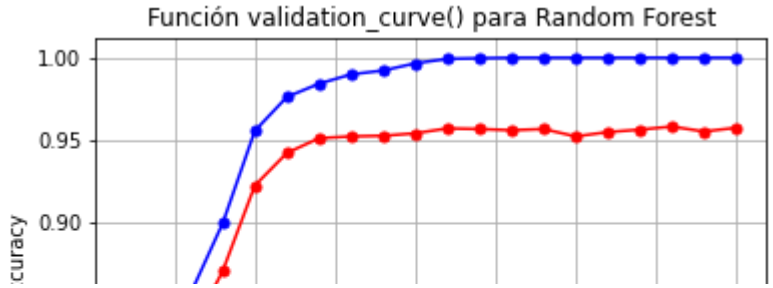

Y observamos que después de max_depth=11, se alcanza un punto alto, y ya no existen cambios significativos para las curvas de training o validación, así como que previo a 4 la métrica de accuracy aún sigue pudiendo subir. Por lo que nos quedamos con un mínimo de 4 y un máximo de 11 para el gridsearch de este parámetro:

Valores del parámetro max_depth

```
#obtenemos el modelo y los parámetros
modeloRFC_iter = RandomForestClassifier()
cvSVM = RepeatedStratifiedKFold(n_splits=5, n_repeats=3, random_state=1)

dicc_grid = [{'ccp_alpha':[0.0001,0.01,0.1,1.0,10.,100],'criterion':['gini','entropy'],
             'max_depth':[4,5,6,7,8,9,10,11],'min_samples_split':[2,3,4,5,6],'class_weight':[

grid2 = GridSearchCV(estimator=modeloDTC_iter,
                     param_grid=dicc_grid,
                     cv=cvSVM,
                     scoring='accuracy',
                     n_jobs=-1,
                     error_score='raise')
```

Corremos el grid search:

```
grid2.fit(Xtv_num, np.ravel(ytv_num))

print('Mejor valor de accuracy obtenido con la mejor combinación:', grid2.best_score_)
print('Mejor combinación de valores encontrados de los hiperparámetros:', grid2.best_params_)
print('Métrica utilizada:', grid2.scoring)
print('Mejor Index:',grid2.best_index_)

grid_splits.append(grid2)
```

```
Mejor valor de accuracy obtenido con la mejor combinación: 0.9616387337057727
Mejor combinación de valores encontrados de los hiperparámetros: {'ccp_alpha': 0.0001,
Métrica utilizada: accuracy
Mejor Index: 115
```

Observamos un accuracy del 96.16% máximo con los hiper parámetros. Ahora probamos el modelo con sus hiper parámetros para los datos de prueba:

```
model_RFC_num = RandomForestClassifier(**grid2.best_params_)

model_RFC_num.fit(Xtv_num, np.ravel(ytv_num))
yhat_num = model_RFC_num.predict(Xtest_num)

score_list.append(get_scores(ytest_num,yhat_num, 'RFC num'))
```

```
Accuracy: 0.9811320754716981
f1_score: 0.9811320754716981
Precision: 0.9811320754716981
Recall: 0.9811320754716981
```

Donde observamos que accuracy aumenta cerca de 1.8%. Lo cual es muy buena indicación de que está generalizando correctamente.

Comenzamos con variables categóricas:

Particionamos los datos:

```
Xtv_cat, Xtest_cat, ytv_cat, ytest_cat = train_test_split(X_cat, Y, test_size=0.15, stratify=
print(Xtv_cat.shape, ': dimensión de datos de entrada de entrenamiento y validación')
print(Xtest_cat.shape, ': dimensión de datos de entrada de prueba')
print(ytv_cat.shape, ': dimensión de variable de salida para entrenamiento y validación')
print(ytest_cat.shape, ': dimensión de variable de salida para prueba')
```

```
(895, 12) : dimensión de datos de entrada de entrenamiento y validación
(159, 12) : dimensión de datos de entrada de prueba
(895, 1) : dimensión de variable de salida para entrenamiento y validación
(159, 1) : dimensión de variable de salida para prueba
```

Decision Tree variables categóricas de calidad de entrada:

Comenzamos viendo la curva de aprendizaje para el parámetro de max_depth:

```
#obtenemos el modelo y los parametros de cross validation
modeloVC = DecisionTreeClassifier()
cvVC = RepeatedStratifiedKFold(n_splits=5, n_repeats=3, random_state=1)

delta_max_depth = np.linspace(1, 20, 20)

train_scores, valid_scores = validation_curve(modeloVC,
                                              Xtv_cat,
                                              np.ravel(ytv_cat),
```

```
                                    param_name="max_depth",
                                    param_range=delta_max_depth,
                                    cv=cvVC,
                                    scoring='accuracy')

train_mean = np.mean(train_scores, axis=1)
train_std = np.std(train_scores, axis=1)
valid_mean = np.mean(valid_scores, axis=1)
valid_std = np.std(valid_scores, axis=1)

# Curva de entrenamiento con la métrica de exactitud (accuracy):
plt.plot(delta_max_depth, train_mean, color='blue', marker='o', markersize=5, label='Training

# Curva de validación:
plt.plot(delta_max_depth, valid_mean, color='red', marker='o', markersize=5, label='Validatio

plt.title('Función validation_curve() para Decision Tree')
plt.xlabel('Valores del parámetro max_depth')
plt.ylabel('Accuracy')
plt.grid(b=True)
plt.legend(loc='lower right')
plt.show()
```

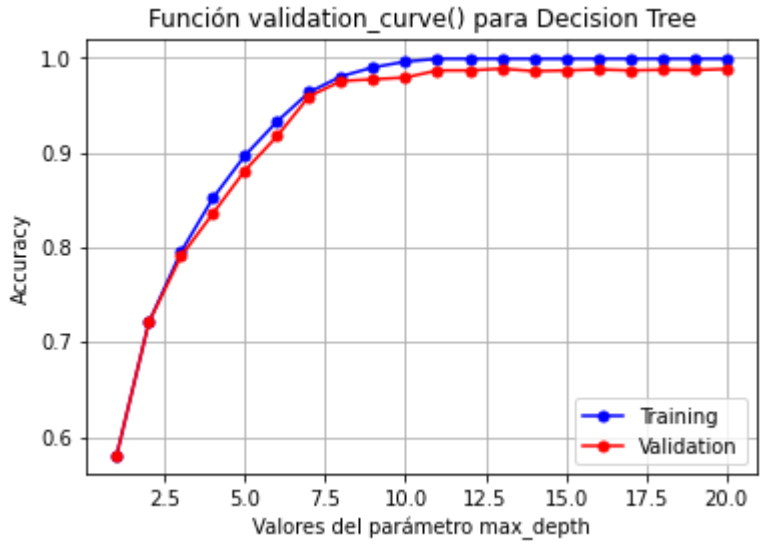

Y observamos que después de max_depth 10 ya no existen cambios significativos para las curvas de training o validación, asi que nos quedamos con un máximo de 10 para el gridsearch para este parámetro:

```
#obtenemos el modelo y los parámetros
modeloDTC_iter = DecisionTreeClassifier()
cvSVM = RepeatedStratifiedKFold(n_splits=5, n_repeats=3, random_state=1)

dicc_grid = [{'ccp_alpha':[0.0001,0.01,0.1,1.0,10.,100],'criterion':['gini','entropy'],
              'max_depth':[1,2,3,4,5,6,7,8,9,10],'min_samples_split':[2,3,4,5,6],'class_weight
```

```
grid3 = GridSearchCV(estimator=modeloDTC_iter,
                     param_grid=dicc_grid,
                     cv=cvSVM,
                     scoring='accuracy',
                     n_jobs=-1,
                     error_score='raise')
```

Corremos el grid search:

```
grid3.fit(Xtv_cat, np.ravel(ytv_cat))

print('Mejor valor de accuracy obtenido con la mejor combinación:', grid3.best_score_)
print('Mejor combinación de valores encontrados de los hiperparámetros:', grid3.best_params_)
print('Métrica utilizada:', grid3.scoring)
print('Mejor Index:',grid3.best_index_)

grid_splits.append(grid3)
```

```
Mejor valor de accuracy obtenido con la mejor combinación: 0.980633147113594
Mejor combinación de valores encontrados de los hiperparámetros: {'ccp_alpha': 0.0001,
Métrica utilizada: accuracy
Mejor Index: 198
```

Observamos un accuracy del 98.06% con los hiper parámetros. Ahora probamos el modelo con sus hiper parámetros para los datos de prueba:

```
model_DTC_cat = DecisionTreeClassifier(**grid3.best_params_)

model_DTC_cat.fit(Xtv_cat, np.ravel(ytv_cat))
yhat_cat = model_DTC_cat.predict(Xtest_cat)

score_list.append(get_scores(ytest_cat,yhat_cat, 'DTC cat'))
```

```
Accuracy: 0.9937106918238994
f1_score: 0.9937106918238994
Precision: 0.9937106918238994
Recall: 0.9937106918238994
```

Donde observamos que accuracy incrementa a 99.37%. Lo cual es muy buena indicación de que está generalizando correctamente.

Random Forest variables categóricas de calidad de entrada:

Comenzamos viendo la curva de aprendizaje para el parámetro de max_depth:

```
#obtenemos el modelo y los parametros de cross validation
modeloVC = RandomForestClassifier()
cvVC = RepeatedStratifiedKFold(n_splits=5, n_repeats=3, random_state=1)

delta_max_depth = np.linspace(1, 20, 20)

train_scores, valid_scores = validation_curve(modeloVC,
                                              Xtv_cat,
                                              np.ravel(ytv_cat),
                                              param_name="max_depth",
                                              param_range=delta_max_depth,
                                              cv=cvVC,
                                              scoring='accuracy')

train_mean = np.mean(train_scores, axis=1)
train_std = np.std(train_scores, axis=1)
valid_mean = np.mean(valid_scores, axis=1)
valid_std = np.std(valid_scores, axis=1)

# Curva de entrenamiento con la métrica de exactitud (accuracy):
plt.plot(delta_max_depth, train_mean, color='blue', marker='o', markersize=5, label='Training

# Curva de validación:
plt.plot(delta_max_depth, valid_mean, color='red', marker='o', markersize=5, label='Validatio

plt.title('Función validation_curve() para Random Forest')
plt.xlabel('Valores del parámetro max_depth')
plt.ylabel('Accuracy')
plt.grid(b=True)
plt.legend(loc='lower right')
plt.show()
```

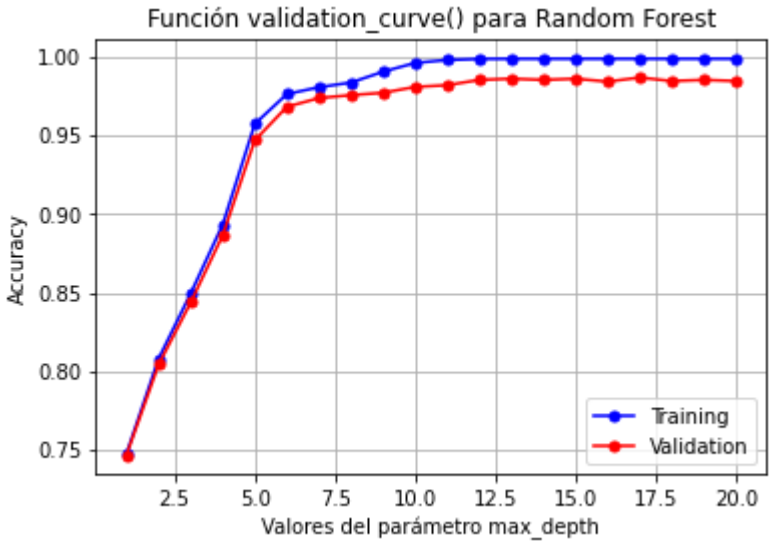

Y observamos que después de max_depth 10 ya no existen cambios significativos para las curvas de training o validación, así como que previo a 4 la métrica de accuracy aún sigue pudiendo subir. Por lo que nos quedamos con un mínimo de 4 y un máximo de 10 para el gridsearch de este parámetro:

```
#obtenemos el modelo y los parámetros
modeloRFC_iter = RandomForestClassifier()
cvSVM = RepeatedStratifiedKFold(n_splits=5, n_repeats=3, random_state=1)

dicc_grid = [{'ccp_alpha':[0.0001,0.01,0.1,1.0,10.,100],'criterion':['gini','entropy'],
             'max_depth':[4,5,6,7,8,9,10],'min_samples_split':[2,3,4,5,6],'class_weight':['ba

grid4 = GridSearchCV(estimator=modeloDTC_iter,
                     param_grid=dicc_grid,
                     cv=cvSVM,
                     scoring='accuracy',
                     n_jobs=-1,
                     error_score='raise')
```

Corremos el grid search:

```
grid4.fit(Xtv_cat, np.ravel(ytv_cat))

print('Mejor valor de accuracy obtenido con la mejor combinación:', grid4.best_score_)
print('Mejor combinación de valores encontrados de los hiperparámetros:', grid4.best_params_)
print('Métrica utilizada:', grid4.scoring)
print('Mejor Index:',grid4.best_index_)

grid_splits.append(grid4)
```

```
Mejor valor de accuracy obtenido con la mejor combinación: 0.9810055865921787
Mejor combinación de valores encontrados de los hiperparámetros: {'ccp_alpha': 0.0001,
Métrica utilizada: accuracy
Mejor Index: 103
```

Observamos un accuracy del 98.10% máximo con los hiper parámetros. Ahora probamos el modelo con sus hiper parámetros para los datos de prueba:

```
model_RFC_cat = RandomForestClassifier(**grid4.best_params_)

model_RFC_cat.fit(Xtv_cat, np.ravel(ytv_cat))
#realizamos las predicciones
yhat_cat = model_RFC_cat.predict(Xtest_cat)
```

```
score_list.append(get_scores(ytest_cat,yhat_cat, 'RFC cat'))
```

```
    Accuracy: 0.9937106918238994
    f1_score: 0.9937106918238994
    Precision: 0.9937106918238994
    Recall: 0.9937106918238994
```

Donde observamos que accuracy incrementa a 99.37%. Lo cual es muy buena indicación de que está generalizando perfectamente.

Explora que clasificador es el más optimo, ejemplo:

Obtenemos los resultados de cada split del cross validation hecho en cada gridsearch:

```
tot_resultados_cv = list()
for grid in grid_splits:
  indx = grid.best_index_
  resultados_cv = list()
  for i in range(15):
    resultados_cv.append(grid.cv_results_['split' + str(i) + '_test_score'][indx])
  tot_resultados_cv.append(resultados_cv)
```

Generamos una lista con los nombres de cada modelo:

```
scores = list()
for scor in score_list:
  scores.append(scor[0])
```

Visualizamos en boxplots la distribución de los resultados de accuracy para cada modelo:

```
sns.set(rc={'figure.figsize':(8,4)})
plt.boxplot(tot_resultados_cv, labels=scores, showmeans=True)
plt.show()
```

Donde observamos que los resultados con menos varianza para cada split, son los de los modelos categóricos. Así mismo, el promedio más alto es también para los categóricos. Por lo que nos quedamos con el modelo de Random Forest con variables categóricas de calidad, ya que entre los dos modelos con variables categóricas, es el que arroja mejores resultados para los datos de prueba:

```
best_RFC_model = RandomForestClassifier(**grid4.best_params_)

best_RFC_model.fit(Xtv_cat, np.ravel(ytv_cat))
yhat = best_RFC_model.predict(Xtest_cat)

print('Accuracy:',accuracy_score(ytest_cat,yhat))
print('F1-score:',f1_score(ytest_cat,yhat,average='micro'))
print('Precision:',precision_score(ytest_cat,yhat,average='micro'))
print('Recall:',recall_score(ytest_cat,yhat,average='micro'))
```

```
Accuracy: 1.0
F1-score: 1.0
Precision: 1.0
Recall: 1.0
```

Un 100% en todas las métricas.

Determina el grado de exactitud a través del reporte de clasificación y análisis de la gráfica de Precision Recall.

- Reporte de clasificacion:

```
target_names = ['Verde', 'Amarillo', 'Rojo']
print(classification_report(ytest_cat, yhat, target_names=target_names))
```

```
                precision    recall  f1-score   support

         Verde       1.00      1.00      1.00        64
      Amarillo       1.00      1.00      1.00        37
          Rojo       1.00      1.00      1.00        58

      accuracy                           1.00       159
     macro avg       1.00      1.00      1.00       159
  weighted avg       1.00      1.00      1.00       159
```

Validamos que tenemos un 100% de exactitud

- Grafica de Precision-Recall

Aplicamos one-hot encoder a los datos de Y de prueba, así como a las predicciones. Ya que es necesario hacer una curva para cada clase

```
Y_ohe = OneHotEncoder()
Y_fitted = Y_ohe.fit(Y)
y_test_multicolum = Y_fitted.transform(ytest_cat).toarray()
y_hat_multicolum = Y_fitted.transform(pd.DataFrame(yhat,columns=['SEMAFORO'])).toarray()
```

Generamos las curvas de precision vs. recall de cada clase:

```
precision = dict()
recall = dict()
clases = ['Verde','Amarillo','Rojo']
for i in range(3):
    precision[i], recall[i], _ = precision_recall_curve(y_test_multicolum[:, i],
                                                        y_hat_multicolum[:, i])
    plt.plot(recall[i], precision[i], lw=2, label=clases[i])
plt.xlabel("recall")
plt.ylabel("precision")
plt.legend(loc="best")
plt.show()
```

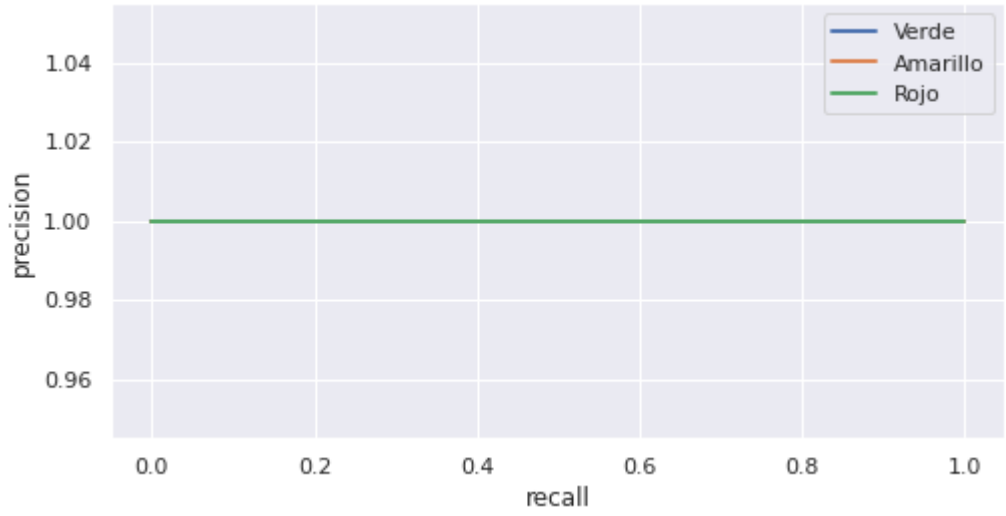

Observamos una exactitud del 100% para cada clase con los datos de prueba.

Generamos como complemento una curva de ROC para cada clase:

```
fpr = dict()
tpr = dict()

for i in range(3):
    fpr[i], tpr[i], _ = roc_curve(y_test_multicolum[:, i],
                                  y_hat_multicolum[:, i])
    plt.plot(fpr[i], tpr[i], lw=2, label=clases[i])

plt.xlabel("false positive rate")
plt.ylabel("true positive rate")
plt.legend(loc="best")
plt.title("ROC curve")
plt.show()
```

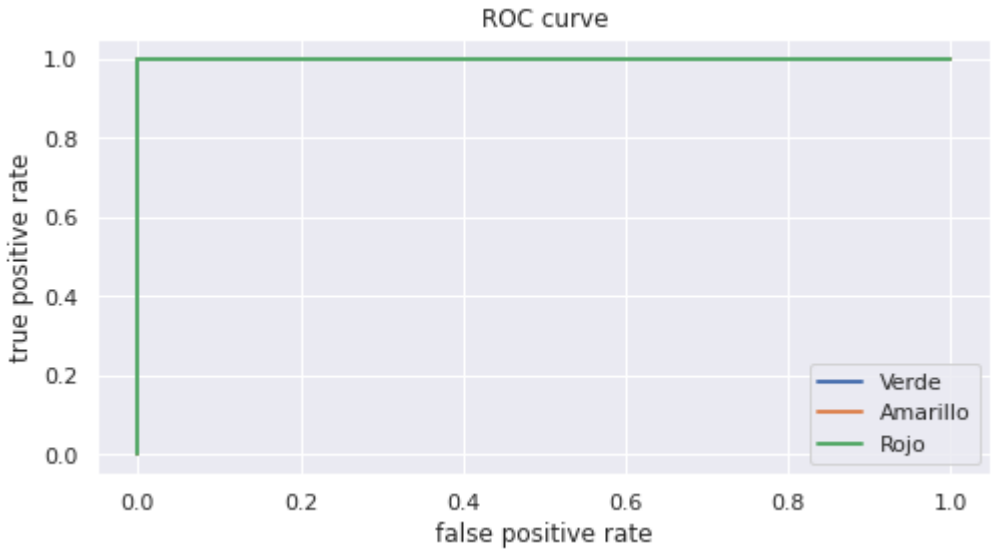

Donde igual obtenemos un 100% de area bajo la curva.

Visualiza los resultados del modelo o las predicciones a través de una matriz de confusión.

Generamos la matriz de confusión:

```
cm = confusion_matrix(ytest_cat, yhat)
```

La visualizamos:

```
df_cm = pd.DataFrame(cm, index = ['Verde','Amarillo','Rojo'], columns = ['Verde','Amarillo','
plt.figure(figsize = (5,5))
```

```
ax = sns.heatmap(df_cm, annot=True, cmap='OrRd', cbar=False)
ax.set(ylabel="Etiquetas Reales", xlabel="Etiquetas de Predicción")
```

```
[Text(21.499999999999996, 0.5, 'Etiquetas Reales'),
 Text(0.5, 21.5, 'Etiquetas de Predicción')]
```

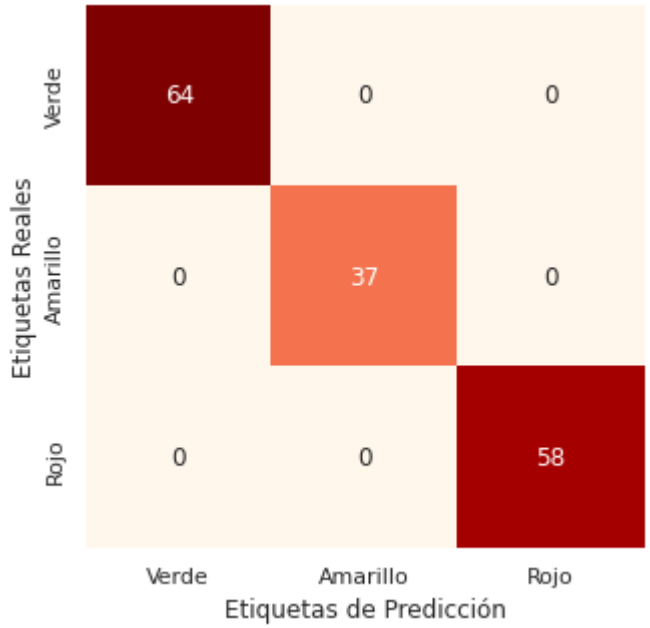

Y encontramos que el modelo consiguió predecir con un 100% de exactitud los datos de prueba. Lo cual nos dice que nuestro modelo generaliza y predice correctamente.

AGUAS SUPERFICIALES

```
url = 'https://github.com/PosgradoMNA/actividades-del-projecto-equipo-52/blob/main/aguas_supe

data_asp = pd.read_csv(url,sep=",")
print(data_asp.shape)
data_asp.head()
```

```
(3479, 35)
```

	CLAVE	LONGITUD	LATITUD	ORGANISMO_DE_CUENCA	SUBTIPO	GRUPO	DBO_mg/L	DQO_mg
1	DLBAJ100	-109.84290	22.90475		10.0	21.0	0.0	1.000000	1.0000
3	DLBAJ102	-109.88604	22.89609		10.0	2.0	0.0	1.000000	1.0000

Selecciona tus variables independientes X y dependiente Y (semáforo)

Separamos las columnas en base a su tipo de variable:

```
#definimos variables numéricas
num_nom_geo = ['LONGITUD','LATITUD']
num_nom_cal = ['DBO_mg/L','DQO_mg/L','SST_mg/L','COLI_FEC_NMP_100mL','E_COLI_NMP_100mL','ENTE
               'OD_PORC_MED','OD_PORC_FON','TOX_D_48_UT','TOX_V_15_UT','TOX_D_48_SUP_UT','TOX_

#definimos variables categóricas
cat_nom = ['ORGANISMO_DE_CUENCA','SUBTIPO','GRUPO']
cat_nom_cal = ['CALIDAD_DBO','CALIDAD_DQO','CALIDAD_SST','CALIDAD_COLI_FEC','CALIDAD_E_COLI',
               'CALIDAD_OD_PORC_MED','CALIDAD_OD_PORC_FON','CALIDAD_TOX_D_48','CALIDAD_TOX_V_
#VARIABLE CATEGORICA DE SALIDA Y
y_nom = ['SEMAFORO']
```

Generamos los datos en Y, y dos tipos de X. Una donde se utilizarán los datos numéricos de calidad, y otra donde se utilizarán los datos categóricos de calidad. Utilizar las variables numéricas y categorías de calidad, donde las categóricas son dependientes de las numéricas, puede afectar la correlación entre variables y eventualmente el modelo.

```
Y = data_asp[['SEMAFORO']]

X_num = data_asp[num_nom_geo + cat_nom + num_nom_cal]
X_cat = data_asp[num_nom_geo + cat_nom + cat_nom_cal]
```

Cambia a label encoding el semáforo, ej, de ["clase 1", "clase 2", "clase 3"] a [1,2,3]

Previamente en la parte 1 del reto ya se cambiaron los valores del semáforo a 1:verde, 2:amarillo, 3:rojo

```
Y.value_counts()
```

```
SEMAFORO
1           1259
2           1129
```

```
3           1091
dtype: int64
```

Realiza un análisis general de las features importances a traves de decision trees o random forest.

Definimos modelos a usar:

```
def get_models():
  modelos = list()
  nombres = list()

  modelos.append(DecisionTreeClassifier())
  nombres.append('DTC')

  modelos.append(RandomForestClassifier())
  nombres.append('RFC')

  return modelos, nombres
```

Obtenemos los feature importance con variables de calidad numéricas:

```
modelos, nombres = get_models()

for m in range(len(modelos)):
  modelos[m].fit(X_num, np.ravel(Y))
  importance = permutation_importance(modelos[m], X_num, Y, n_repeats=10)
  print('\033[1m' + nombres[m] + '\033[0m')
  for i,v in enumerate(importance['importances_mean']):
    print(X_num.columns[i]+':', v.round(3))
  f = plt.figure()
  plt.bar(X_num.columns, importance['importances_mean'])
  plt.xticks(rotation='vertical')
  plt.show()
```

DTC

LONGITUD: 0.0
LATITUD: 0.005
ORGANISMO_DE_CUENCA: 0.009
SUBTIPO: 0.001
GRUPO: 0.001
DBO_mg/L: 0.022
DQO_mg/L: 0.329
SST_mg/L: 0.045
COLI_FEC_NMP_100mL: 0.27
E_COLI_NMP_100mL: 0.124
ENTEROC_NMP_100mL: 0.06
OD_PORC: 0.029
OD_PORC_SUP: 0.081
OD_PORC_MED: 0.0
OD_PORC_FON: 0.03
TOX_D_48_UT: 0.0
TOX_V_15_UT: 0.0
TOX_D_48_SUP_UT: 0.001
TOX_FIS_SUP_15_UT: 0.001

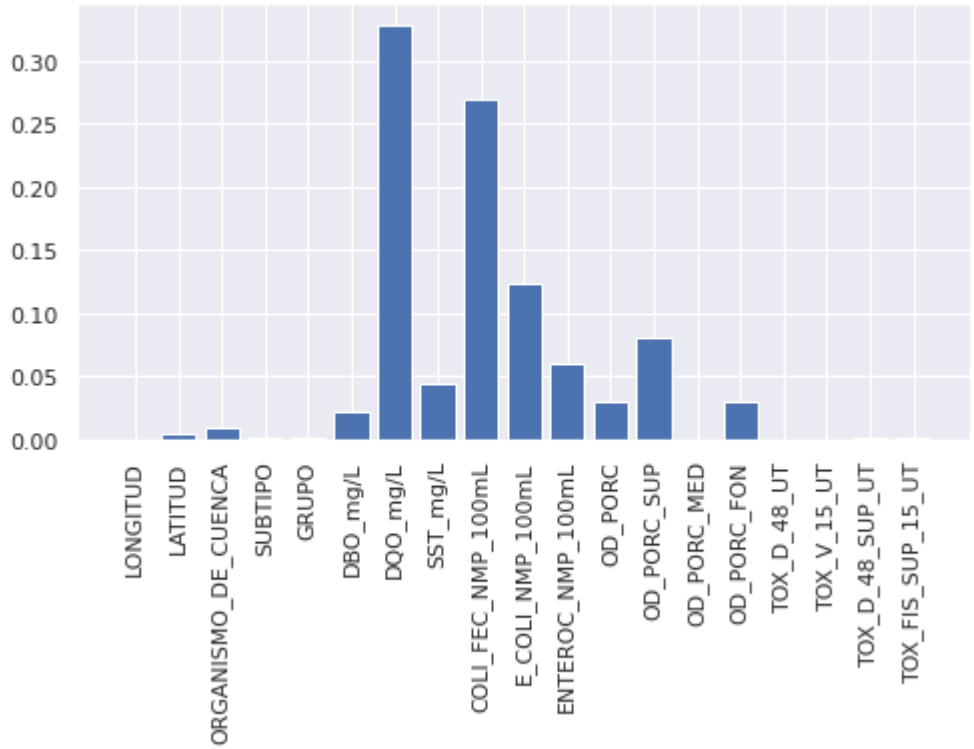

RFC

LONGITUD: 0.002
LATITUD: 0.001
ORGANISMO_DE_CUENCA: 0.0
SUBTIPO: 0.001
GRUPO: 0.002
DBO_mg/L: 0.002
DQO_mg/L: 0.378
SST_mg/L: 0.033
COLI_FEC_NMP_100mL: 0.285
E_COLI_NMP_100mL: 0.009
ENTEROC_NMP_100mL: 0.056
OD_PORC: 0.004
OD_PORC_SUP: 0.014

```
OD_PORC_MED: 0.0
OD_PORC_FON: 0.008
TOX_D_48_UT: 0.0
TOX_V_15_UT: 0.0
TOX_D_48_SUP_UT: 0.001
TOX_FIS_SUP_15_UT: 0.0
```

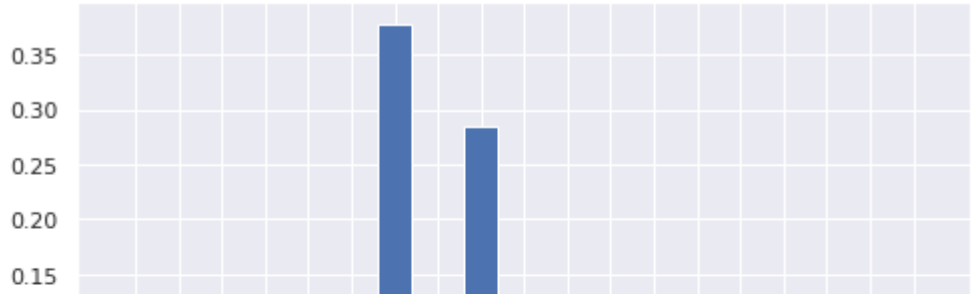

Y donde observamos que las variables de ubicación geográfica, así como organismo de cuenca, subtipo y grupo no tienen una importancia significativa. Mientras que las de calidad, son algunas las que dan la mayor importancia. Pero vemos que OD_PORC_MED, TOX_D_48_UT, TOX_V_15_UT, TOX_D_48_SUP_UT, y TOX_FIS_SUP_15_UT no tienen efecto alguno.

Obtenemos los feature importance con las variables de calidad categóricas:

```
modelos, nombres = get_models()

for m in range(len(modelos)):
  modelos[m].fit(X_cat, np.ravel(Y))
  importance = permutation_importance(modelos[m], X_cat, Y, n_repeats=10)
  print('\033[1m' + nombres[m] + '\033[0m')
  for i,v in enumerate(importance['importances_mean']):
    print(X_cat.columns[i]+':', v.round(3))
  f = plt.figure()
  plt.bar(X_cat.columns, importance['importances_mean'])
  plt.xticks(rotation='vertical')
  plt.show()
```

DTC

LONGITUD: 0.0
LATITUD: 0.0
ORGANISMO_DE_CUENCA: 0.0
SUBTIPO: 0.0
GRUPO: 0.0
CALIDAD_DBO: 0.021
CALIDAD_DQO: 0.332
CALIDAD_SST: 0.046
CALIDAD_COLI_FEC: 0.279
CALIDAD_E_COLI: 0.12
CALIDAD_ENTEROC: 0.058
CALIDAD_OD_PORC: 0.036
CALIDAD_OD_PORC_SUP: 0.021
CALIDAD_OD_PORC_MED: 0.0
CALIDAD_OD_PORC_FON: 0.027
CALIDAD_TOX_D_48: 0.0
CALIDAD_TOX_V_15: 0.0
CALIDAD TOX_D_48_SUP: 0.001
CALIDAD_TOX_FIS_SUP_15: 0.001

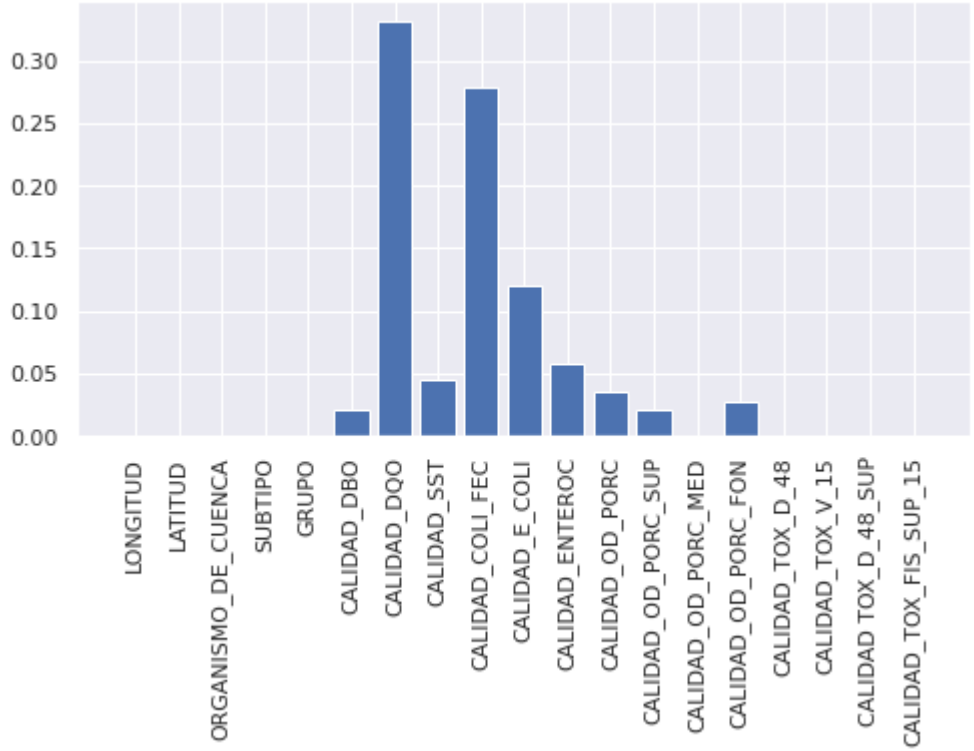

RFC

LONGITUD: 0.0
LATITUD: 0.0
ORGANISMO_DE_CUENCA: 0.0
SUBTIPO: 0.0
GRUPO: 0.0
CALIDAD_DBO: 0.002
CALIDAD_DQO: 0.353
CALIDAD_SST: 0.039
CALIDAD_COLI_FEC: 0.132
CALIDAD_E_COLI: 0.024
CALIDAD_ENTEROC: 0.053
CALIDAD_OD_PORC: 0.011
CALIDAD OD PORC SUP: 0.019

```
CALIDAD_OD_PORC_MED: 0.0
CALIDAD_OD_PORC_FON: 0.024
CALIDAD_TOX_D_48: 0.0
CALIDAD_TOX_V_15: 0.0
CALIDAD TOX_D_48_SUP: 0.001
CALIDAD_TOX_FIS_SUP_15: 0.0
```

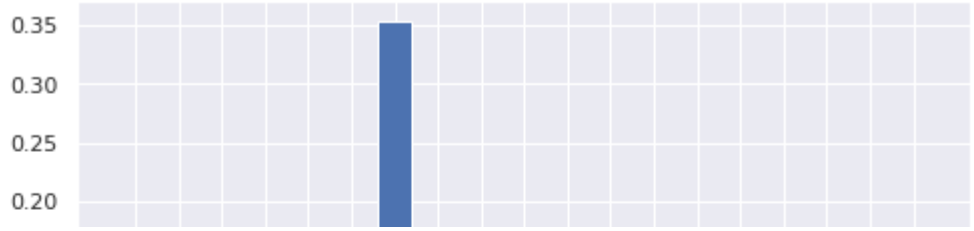

Y donde observamos que las variables de ubicación geográfica, así como organismo de cuenca, subtipo y grupo no tienen una importancia significativa. Mientras que las de calidad, son algunas las que dan la mayor importancia. Pero vemos que CALIDAD_OD_PORC_MED, CALIDAD_TOX_D_48, CALIDAD_TOX_V_15, TOX_D_48_SUP, y CALIDAD_TOX_FIS_SUP_15 no tienen efecto alguno.

Selecciona las variables de mayor importancia.

Removemos de nuestras listas de columnas las variables que no tienen feature importance

```
num_nom_cal = ['DBO_mg/L','DQO_mg/L','SST_mg/L','COLI_FEC_NMP_100mL','E_COLI_NMP_100mL','ENTE
               'OD_PORC_FON']

cat_nom_cal = ['CALIDAD_DBO','CALIDAD_DQO','CALIDAD_SST','CALIDAD_COLI_FEC','CALIDAD_E_COLI',
                'CALIDAD_OD_PORC_FON']
```

Generamos nuevas dataframes con las columnas a utilizar:

```
X_num = data_asp[num_nom_cal]
X_cat = data_asp[cat_nom_cal]
```

Realiza tu clasificador, recuerda dividir los datos de manera balanceada (auxiliate de train test split)

- Comenzamos con variables numéricas:

```
score_list = list()
grid_splits = list()
```

```
def get_scores(yreal, ypred, model, aver='micro'):
  temp_list = list()

  temp_list.append(model)
  accu = accuracy_score(yreal,ypred)
  f1 = f1_score(yreal,ypred,average=aver)
  precision = precision_score(yreal,ypred,average=aver)
  recall = recall_score(yreal,ypred,average=aver)

  temp_list.append(accu)
  temp_list.append(f1)
  temp_list.append(precision)
  temp_list.append(recall)
  print('Accuracy:', accu)
  print('f1_score:', f1)
  print('Precision:', precision)
  print('Recall:', recall)

  return temp_list
```

Sabemos de la parte 1 que las clases de salida tienen diferentes proporciones, por lo que utilizamos el parámetro stratify:

```
Xtv_num, Xtest_num, ytv_num, ytest_num = train_test_split(X_num, Y, test_size=0.15, stratify=
print(Xtv_num.shape, ': dimensión de datos de entrada de entrenamiento y validación')
print(Xtest_num.shape, ': dimensión de datos de entrada de prueba')
print(ytv_num.shape, ': dimensión de variable de salida para entrenamiento y validación')
print(ytest_num.shape, ': dimensión de variable de salida para prueba')
```

```
(2957, 9) : dimensión de datos de entrada de entrenamiento y validación
(522, 9) : dimensión de datos de entrada de prueba
(2957, 1) : dimensión de variable de salida para entrenamiento y validación
(522, 1) : dimensión de variable de salida para prueba
```

- Decision Tree variables numéricas de calidad de entrada:

Comenzamos viendo la curva de aprendizaje para el parámetro de max_depth:

```
#obtenemos el modelo y los parametros de cross validation
modeloVC = DecisionTreeClassifier()
cvVC = RepeatedStratifiedKFold(n_splits=5, n_repeats=3, random_state=1)

delta_max_depth = np.linspace(1, 20, 20)

train_scores, valid_scores = validation_curve(modeloVC,
                                              Xtv_num,
                                              np.ravel(ytv_num),
```

```
                                        param_name="max_depth",
                                        param_range=delta_max_depth,
                                        cv=cvVC,
                                        scoring='accuracy')

train_mean = np.mean(train_scores, axis=1)
train_std = np.std(train_scores, axis=1)
valid_mean = np.mean(valid_scores, axis=1)
valid_std = np.std(valid_scores, axis=1)

# Curva de entrenamiento con la métrica de exactitud (accuracy):
plt.plot(delta_max_depth, train_mean, color='blue', marker='o', markersize=5, label='Training

# Curva de validación:
plt.plot(delta_max_depth, valid_mean, color='red', marker='o', markersize=5, label='Validatio

plt.title('Función validation_curve() para Decision Tree')
plt.xlabel('Valores del parámetro max_depth')
plt.ylabel('Accuracy')
plt.grid(b=True)
plt.legend(loc='lower right')
plt.show()
```

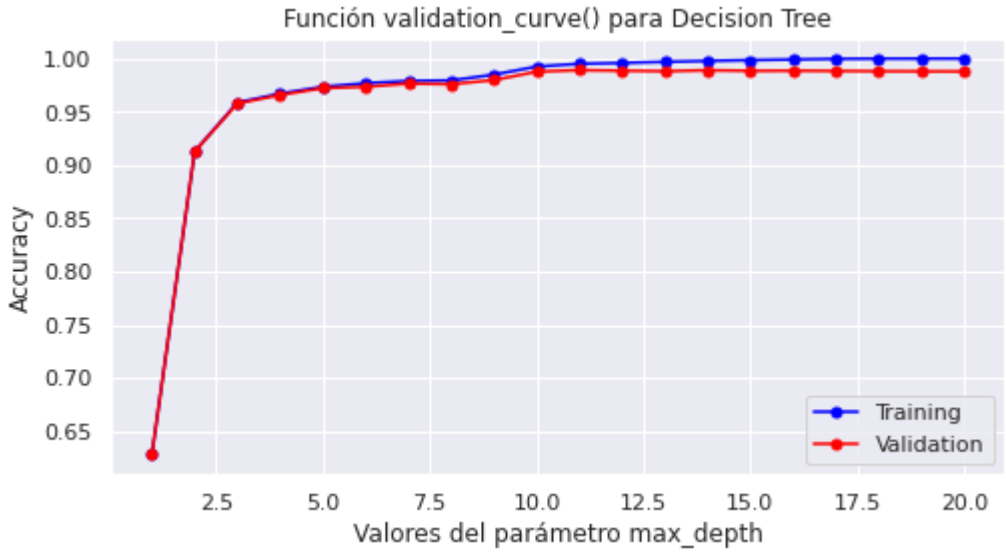

Y observamos que después de max_depth 10 ya no existen cambios significativos para las curvas de training o validación, asi que nos quedamos minimo de 2, ya que con ello estamos por arriba del 90% y con un máximo de 10 para el gridsearch para este parámetro:

```
#obtenemos el modelo y los parámetros
modeloDTC_iter = DecisionTreeClassifier()
cvSVM = RepeatedStratifiedKFold(n_splits=5, n_repeats=3, random_state=1)

dicc_grid = [{'ccp_alpha':[0.0001,0.01,0.1,1.0,10.,100],'criterion':['gini','entropy'],
```

```
              'max_depth':[2,3,4,5,6,7,8,9,10],'min_samples_split':[2,3,4,5,6],'class_weight':

grid1 = GridSearchCV(estimator=modeloDTC_iter,
                     param_grid=dicc_grid,
                     cv=cvSVM,
                     scoring='accuracy',
                     n_jobs=-1,
                     error_score='raise')
```

Corremos el grid search:

```
grid1.fit(Xtv_num, np.ravel(ytv_num))

print('Mejor valor de accuracy obtenido con la mejor combinación:', grid1.best_score_)
print('Mejor combinación de valores encontrados de los hiperparámetros:', grid1.best_params_)
print('Métrica utilizada:', grid1.scoring)
print('Mejor Index:',grid1.best_index_)

grid_splits.append(grid1)
```

```
Mejor valor de accuracy obtenido con la mejor combinación: 0.9897415816832059
Mejor combinación de valores encontrados de los hiperparámetros: {'ccp_alpha': 0.0001,
Métrica utilizada: accuracy
Mejor Index: 40
```

Observamos un accuracy del 98.97% máximo con los hiper parámetros. Ahora probamos el modelo con sus hiper parámetros para los datos de prueba:

```
model_DTC_num = DecisionTreeClassifier(**grid1.best_params_)

model_DTC_num.fit(Xtv_num, ytv_num)
#realizamos las predicciones
yhat_num = model_DTC_num.predict(Xtest_num)

score_list.append(get_scores(ytest_num,yhat_num, 'DTC num'))
```

```
Accuracy: 0.9885057471264368
f1_score: 0.9885057471264368
Precision: 0.9885057471264368
Recall: 0.9885057471264368
```

Donde observamos que accuracy disminuye una muy pequeña cantidad. Lo que sugiere que el modelo practicamente esta prediciendo bien. Es un valor muy aceptable.

- Random Forest variables numéricas de calidad de entrada:

Comenzamos viendo la curva de aprendizaje para el parámetro de max_depth:

```
#obtenemos el modelo y los parametros de cross validation
modeloVC = RandomForestClassifier()
cvVC = RepeatedStratifiedKFold(n_splits=5, n_repeats=3, random_state=1)

delta_max_depth = np.linspace(1, 20, 20)

train_scores, valid_scores = validation_curve(modeloVC,
                                              Xtv_num,
                                              np.ravel(ytv_num),
                                              param_name="max_depth",
                                              param_range=delta_max_depth,
                                              cv=cvVC,
                                              scoring='accuracy')

train_mean = np.mean(train_scores, axis=1)
train_std = np.std(train_scores, axis=1)
valid_mean = np.mean(valid_scores, axis=1)
valid_std = np.std(valid_scores, axis=1)

# Curva de entrenamiento con la métrica de exactitud (accuracy):
plt.plot(delta_max_depth, train_mean, color='blue', marker='o', markersize=5, label='Training

# Curva de validación:
plt.plot(delta_max_depth, valid_mean, color='red', marker='o', markersize=5, label='Validatio

plt.title('Función validation_curve() para Random Forest')
plt.xlabel('Valores del parámetro max_depth')
plt.ylabel('Accuracy')
plt.grid(b=True)
plt.legend(loc='lower right')
plt.show()
```

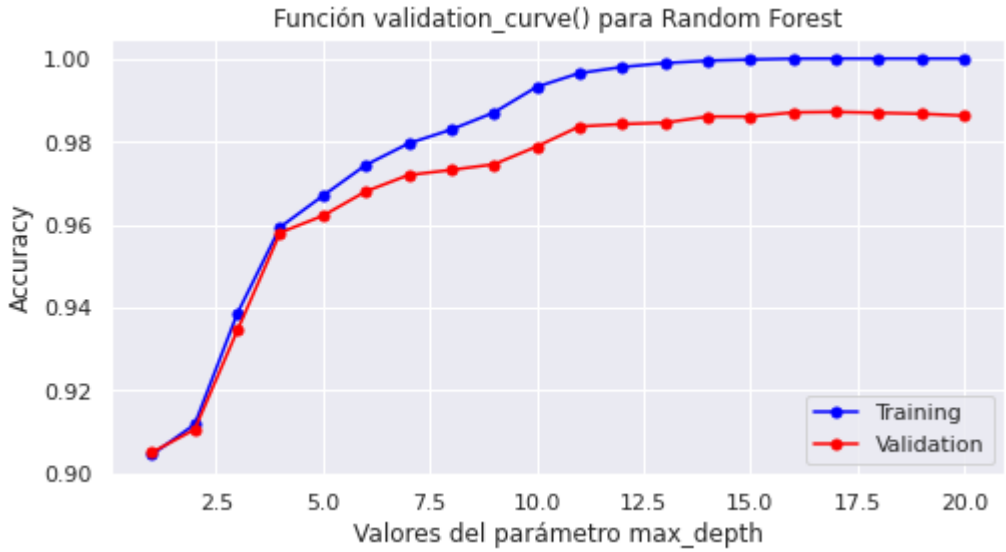

Y observamos que después de max_depth 12 ya no existen cambios significativos para las curvas de training o validación, así como que previo a 4 la métrica de accuracy aún sigue pudiendo subir. Por lo que nos quedamos con un mínimo de 4 y un máximo de 12 para el gridsearch de este parámetro:

```
#obtenemos el modelo y los parámetros
modeloRFC_iter = RandomForestClassifier()
cvSVM = RepeatedStratifiedKFold(n_splits=5, n_repeats=3, random_state=1)

dicc_grid = [{'ccp_alpha':[0.0001,0.01,0.1,1.0,10.,100],'criterion':['gini','entropy'],
             'max_depth':[4,5,6,7,8,9,10,11,12],'min_samples_split':[2,3,4,5,6],'class_weight

grid2 = GridSearchCV(estimator=modeloDTC_iter,
                     param_grid=dicc_grid,
                     cv=cvSVM,
                     scoring='accuracy',
                     n_jobs=-1,
                     error_score='raise')
```

Corremos el grid search:

```
grid2.fit(Xtv_num, np.ravel(ytv_num))

print('Mejor valor de accuracy obtenido con la mejor combinación:', grid2.best_score_)
print('Mejor combinación de valores encontrados de los hiperparámetros:', grid2.best_params_)
print('Métrica utilizada:', grid2.scoring)
print('Mejor Index:',grid2.best_index_)

grid_splits.append(grid2)
```

```
Mejor valor de accuracy obtenido con la mejor combinación: 0.9897415816832059
Mejor combinación de valores encontrados de los hiperparámetros: {'ccp_alpha': 0.0001,
Métrica utilizada: accuracy
Mejor Index: 38
```

Observamos un accuracy del 98.97% máximo con los hiper parámetros. Ahora probamos el modelo con sus hiper parámetros para los datos de prueba:

```
model_RFC_num = RandomForestClassifier(**grid2.best_params_)

model_RFC_num.fit(Xtv_num, np.ravel(ytv_num))
yhat_num = model_RFC_num.predict(Xtest_num)

score_list.append(get_scores(ytest_num,yhat_num, 'RFC num'))
```

```
Accuracy: 0.9827586206896551
f1_score: 0.9827586206896551
Precision: 0.9827586206896551
Recall: 0.9827586206896551
```

Donde observamos que el accuracy disminuye 0.7% aproximadamente con los datos de prueba. Lo cual indica que está prediciendo bien, quizás un muy pequeño sobreentrenamiento, pero muy dentro de valores aceptables.

- Comenzamos con variables categóricas:

Particionamos los datos:

```
Xtv_cat, Xtest_cat, ytv_cat, ytest_cat = train_test_split(X_cat, Y, test_size=0.15, stratify=
print(Xtv_cat.shape, ': dimensión de datos de entrada de entrenamiento y validación')
print(Xtest_cat.shape, ': dimensión de datos de entrada de prueba')
print(ytv_cat.shape, ': dimensión de variable de salida para entrenamiento y validación')
print(ytest_cat.shape, ': dimensión de variable de salida para prueba')
```

```
(2957, 9) : dimensión de datos de entrada de entrenamiento y validación
(522, 9) : dimensión de datos de entrada de prueba
(2957, 1) : dimensión de variable de salida para entrenamiento y validación
(522, 1) : dimensión de variable de salida para prueba
```

- Decision Tree variables categóricas de calidad de entrada:

Comenzamos viendo la curva de aprendizaje para el parámetro de max_depth:

```
#obtenemos el modelo y los parametros de cross validation
modeloVC = DecisionTreeClassifier()
cvVC = RepeatedStratifiedKFold(n_splits=5, n_repeats=3, random_state=1)

delta_max_depth = np.linspace(1, 20, 20)

train_scores, valid_scores = validation_curve(modeloVC,
                                              Xtv_cat,
                                              np.ravel(ytv_cat),
                                              param_name="max_depth",
                                              param_range=delta_max_depth,
                                              cv=cvVC,
                                              scoring='accuracy')

train_mean = np.mean(train_scores, axis=1)
train_std = np.std(train_scores, axis=1)
valid_mean = np.mean(valid_scores, axis=1)
```

```
valid_std = np.std(valid_scores, axis=1)

# Curva de entrenamiento con la métrica de exactitud (accuracy):
plt.plot(delta_max_depth, train_mean, color='blue', marker='o', markersize=5, label='Training

# Curva de validación:
plt.plot(delta_max_depth, valid_mean, color='red', marker='o', markersize=5, label='Validatio

plt.title('Función validation_curve() para Decision Tree')
plt.xlabel('Valores del parámetro max_depth')
plt.ylabel('Accuracy')
plt.grid(b=True)
plt.legend(loc='lower right')
plt.show()
```

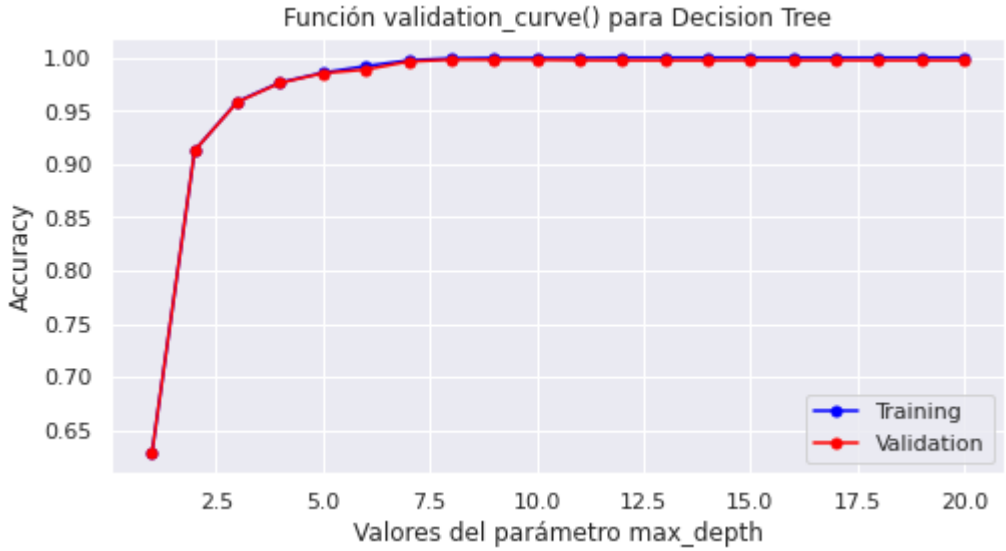

Y observamos que después de max_depth=7 ya no existen cambios significativos para las curvas de training o validación, asi que nos quedamos con un máximo de 7 para el gridsearch para este parámetro:

```
#obtenemos el modelo y los parámetros
modeloDTC_iter = DecisionTreeClassifier()
cvSVM = RepeatedStratifiedKFold(n_splits=5, n_repeats=3, random_state=1)

dicc_grid = [{'ccp_alpha':[0.0001,0.01,0.1,1.0,10.,100],'criterion':['gini','entropy'],
             'max_depth':[1,2,3,4,5,6,7],'min_samples_split':[2,3,4,5,6],'class_weight':['bal

grid3 = GridSearchCV(estimator=modeloDTC_iter,
                     param_grid=dicc_grid,
                     cv=cvSVM,
                     scoring='accuracy',
                     n_jobs=-1,
                     error_score='raise')
```

Corremos el grid search:

```
grid3.fit(Xtv_cat, np.ravel(ytv_cat))

print('Mejor valor de accuracy obtenido con la mejor combinación:', grid3.best_score_)
print('Mejor combinación de valores encontrados de los hiperparámetros:', grid3.best_params_)
print('Métrica utilizada:', grid3.scoring)
print('Mejor Index:',grid3.best_index_)

grid_splits.append(grid3)
```

```
Mejor valor de accuracy obtenido con la mejor combinación: 0.9962794012286398
Mejor combinación de valores encontrados de los hiperparámetros: {'ccp_alpha': 0.01, 'cl
Métrica utilizada: accuracy
Mejor Index: 205
```

Observamos un accuracy del 99.62% máximo con los hiper parámetros. Ahora probamos el modelo con sus hiper parámetros para los datos de prueba:

```
model_DTC_cat = DecisionTreeClassifier(**grid3.best_params_)

model_DTC_cat.fit(Xtv_cat, np.ravel(ytv_cat))
yhat_cat = model_DTC_cat.predict(Xtest_cat)

score_list.append(get_scores(ytest_cat,yhat_cat, 'DTC cat'))
```

```
Accuracy: 0.9923371647509579
f1_score: 0.9923371647509579
Precision: 0.9923371647509579
Recall: 0.9923371647509579
```

Donde observamos que el accuracy disminuye centésimas con los datos de prueba. Lo cual indica que el modelo está prediciendo bien.

- Random Forest variables categóricas de calidad de entrada:

Comenzamos viendo la curva de aprendizaje para el parámetro de max_depth:

```
#obtenemos el modelo y los parametros de cross validation
modeloVC = RandomForestClassifier()
cvVC = RepeatedStratifiedKFold(n_splits=5, n_repeats=3, random_state=1)

delta_max_depth = np.linspace(1, 20, 20)
```

```
train_scores, valid_scores = validation_curve(modeloVC,
                                              Xtv_cat,
                                              np.ravel(ytv_cat),
                                              param_name="max_depth",
                                              param_range=delta_max_depth,
                                              cv=cvVC,
                                              scoring='accuracy')

train_mean = np.mean(train_scores, axis=1)
train_std = np.std(train_scores, axis=1)
valid_mean = np.mean(valid_scores, axis=1)
valid_std = np.std(valid_scores, axis=1)

# Curva de entrenamiento con la métrica de exactitud (accuracy):
plt.plot(delta_max_depth, train_mean, color='blue', marker='o', markersize=5, label='Training

# Curva de validación:
plt.plot(delta_max_depth, valid_mean, color='red', marker='o', markersize=5, label='Validatio

plt.title('Función validation_curve() para Random Forest')
plt.xlabel('Valores del parámetro max_depth')
plt.ylabel('Accuracy')
plt.grid(b=True)
plt.legend(loc='lower right')
plt.show()
```

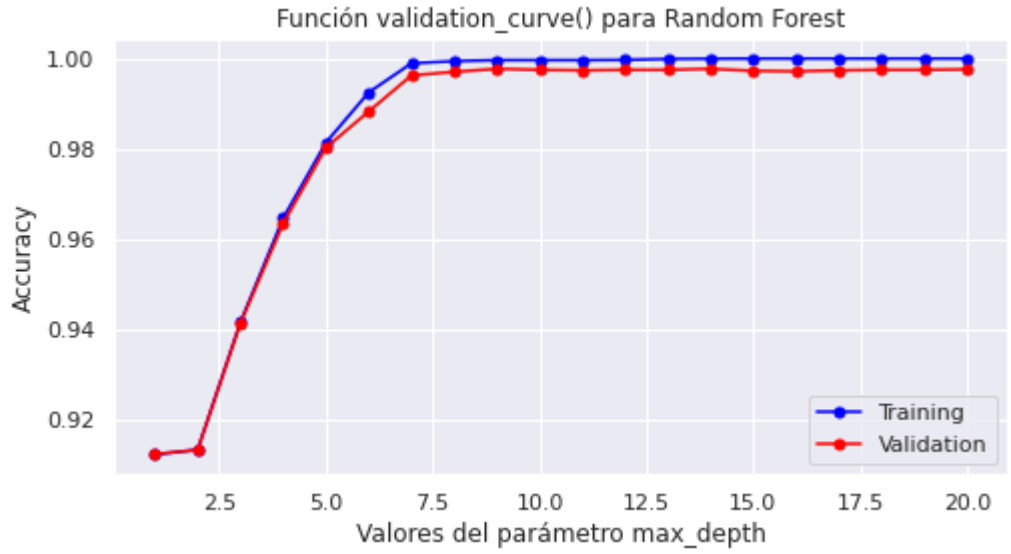

Y observamos que después de max_depth 8 ya no existen cambios significativos para las curvas de training o validación, así como que previo a 4 la métrica de accuracy aún sigue pudiendo subir. Por lo que nos quedamos con un mínimo de 4 y un máximo de 8 para el gridsearch de este parámetro:

```
#obtenemos el modelo y los parámetros
modeloRFC_iter = RandomForestClassifier()
cvSVM = RepeatedStratifiedKFold(n_splits=5, n_repeats=3, random_state=1)

dicc_grid = [{'ccp_alpha':[0.0001,0.01,0.1,1.0,10.,100],'criterion':['gini','entropy'],
              'max_depth':[4,5,6,7,8],'min_samples_split':[2,3,4,5,6],'class_weight':['balance

grid4 = GridSearchCV(estimator=modeloDTC_iter,
                     param_grid=dicc_grid,
                     cv=cvSVM,
                     scoring='accuracy',
                     n_jobs=-1,
                     error_score='raise')
```

Corremos el grid search:

```
grid4.fit(Xtv_cat, np.ravel(ytv_cat))

print('Mejor valor de accuracy obtenido con la mejor combinación:', grid4.best_score_)
print('Mejor combinación de valores encontrados de los hiperparámetros:', grid4.best_params_)
print('Métrica utilizada:', grid4.scoring)
print('Mejor Index:',grid4.best_index_)

grid_splits.append(grid4)
```

```
Mejor valor de accuracy obtenido con la mejor combinación: 0.9979708769683387
Mejor combinación de valores encontrados de los hiperparámetros: {'ccp_alpha': 0.01, 'cl
Métrica utilizada: accuracy
Mejor Index: 145
```

Observamos un accuracy del 99.79% máximo con los hiper parámetros. Ahora probamos el modelo con sus hiper parámetros para los datos de prueba:

```
model_RFC_cat = RandomForestClassifier(**grid4.best_params_)

model_RFC_cat.fit(Xtv_cat, np.ravel(ytv_cat))
#realizamos las predicciones
yhat_cat = model_RFC_cat.predict(Xtest_cat)

score_list.append(get_scores(ytest_cat,yhat_cat, 'RFC cat'))
```

```
Accuracy: 0.9961685823754789
f1_score: 0.9961685823754789
Precision: 0.9961685823754789
Recall: 0.9961685823754789
```

Donde observamos que el accuracy disminuye aproximadamente en 0.18% con los datos de prueba. Lo cual indica que el modelo esta prediciendo bien.

Explora que clasificador es el más optimo, ejemplo:

Obtenemos los resultados de cada split del cross validation hecho en cada gridsearch:

```
tot_resultados_cv = list()
for grid in grid_splits:
  indx = grid.best_index_
  resultados_cv = list()
  for i in range(15):
    resultados_cv.append(grid.cv_results_['split' + str(i) + '_test_score'][indx])
  tot_resultados_cv.append(resultados_cv)
```

Generamos una lista con los nombres de cada modelo:

```
scores = list()
for scor in score_list:
  scores.append(scor[0])
```

Visualizamos en boxplots la distribución de los resultados de accuracy para cada modelo:

```
sns.set(rc={'figure.figsize':(8,4)})
plt.boxplot(tot_resultados_cv, labels=scores, showmeans=True)
plt.show()
```

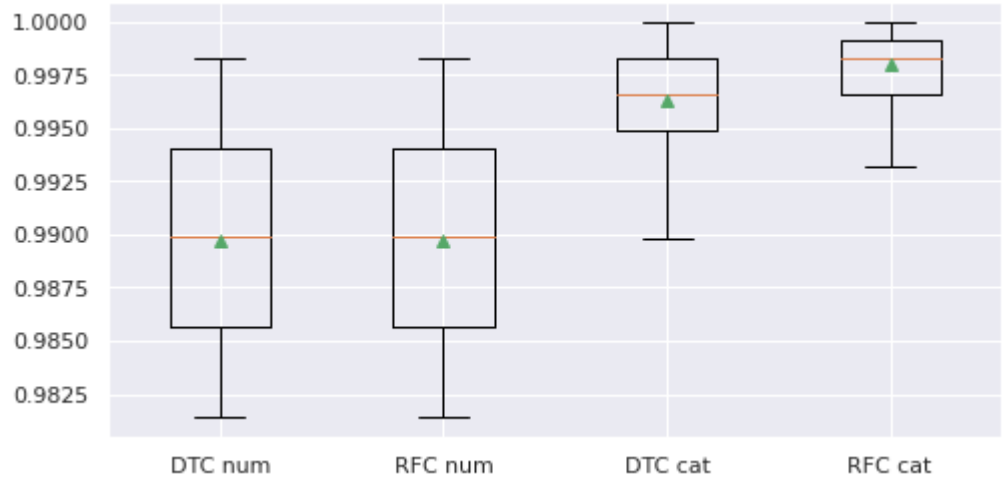

Donde observamos que los resultados con menos varianza para cada split, son los de los modelos categóricos. Así mismo, el promedio más alto es también para los categóricos. Por lo que nos quedamos con el modelo de Random Forest con variables categóricas de calidad, ya que entre los dos modelos con variables categóricas, es el que arroja mejores resultados para los datos de prueba:

```
best_RFC_model = RandomForestClassifier(**grid4.best_params_)

best_RFC_model.fit(Xtv_cat, np.ravel(ytv_cat))
yhat = best_RFC_model.predict(Xtest_cat)

print('Accuracy:',accuracy_score(ytest_cat,yhat))
print('F1-score:',f1_score(ytest_cat,yhat,average='micro'))
print('Precision:',precision_score(ytest_cat,yhat,average='micro'))
print('Recall:',recall_score(ytest_cat,yhat,average='micro'))
```

```
Accuracy: 0.9961685823754789
F1-score: 0.9961685823754789
Precision: 0.9961685823754789
Recall: 0.9961685823754789
```

Un 99.62% en sus métricas.

Determina el grado de exactitud a través del reporte de clasificación y análisis de la gráfica de Precision Recall.

- Reporte de clasificacion:

```
target_names = ['Verde', 'Amarillo', 'Rojo']
print(classification_report(ytest_cat, yhat, target_names=target_names))
```

```
              precision    recall  f1-score   support

       Verde       0.99      1.00      1.00       189
    Amarillo       0.99      1.00      1.00       169
       Rojo        1.00      0.99      0.99       164

    accuracy                           1.00       522
   macro avg       1.00      1.00      1.00       522
weighted avg       1.00      1.00      1.00       522
```

Validamos que tenemos un 100% de accuracy. Pero que para precision, recall, y f1-score obtenemos 99% en algunas clases.

- Grafica de Precision-Recall

Aplicamos one-hot encoder a los datos de Y de prueba, así como a las predicciones. Ya que es necesario hacer una curva para cada clase

```
Y_ohe = OneHotEncoder()
Y_fitted = Y_ohe.fit(Y)
y_test_multicolum = Y_fitted.transform(ytest_cat).toarray()
y_hat_multicolum = Y_fitted.transform(pd.DataFrame(yhat,columns=['SEMAFORO'])).toarray()
```

Generamos las curvas de precision vs. recall de cada clase:

```
precision = dict()
recall = dict()
clases = ['Verde','Amarillo','Rojo']
for i in range(3):
    precision[i], recall[i], _ = precision_recall_curve(y_test_multicolum[:, i],
                                                        y_hat_multicolum[:, i])
    plt.plot(recall[i], precision[i], lw=2, label=clases[i])
plt.xlabel("recall")
plt.ylabel("precision")
plt.legend(loc="best")
plt.show()
```

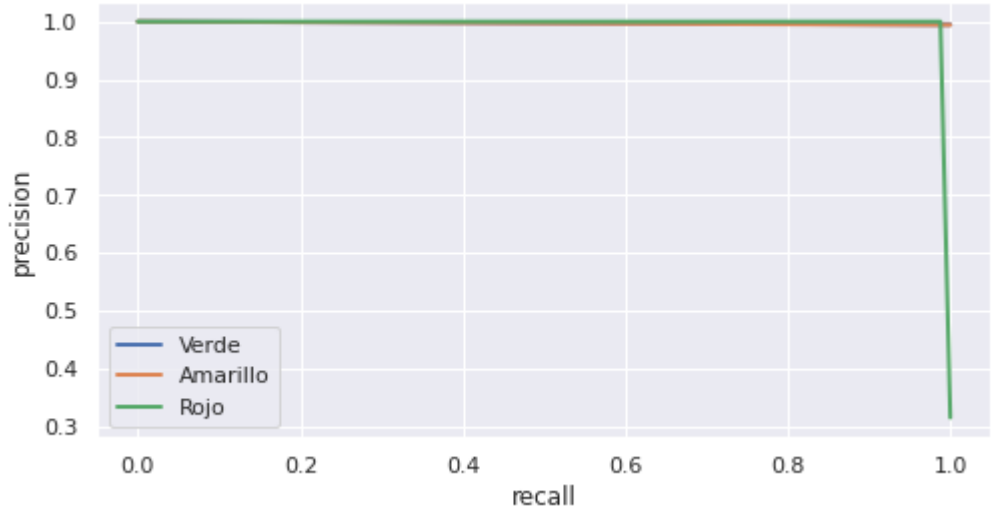

Observamos una exactitud cercana al 99% para cada clase con los datos de prueba.

Generamos como complemento una curva de ROC para cada clase:

```
fpr = dict()
tpr = dict()
```

```
for i in range(3):
    fpr[i], tpr[i], _ = roc_curve(y_test_multicolum[:, i],
                                  y_hat_multicolum[:, i])
    plt.plot(fpr[i], tpr[i], lw=2, label=clases[i])

plt.xlabel("false positive rate")
plt.ylabel("true positive rate")
plt.legend(loc="best")
plt.title("ROC curve")
plt.show()
```

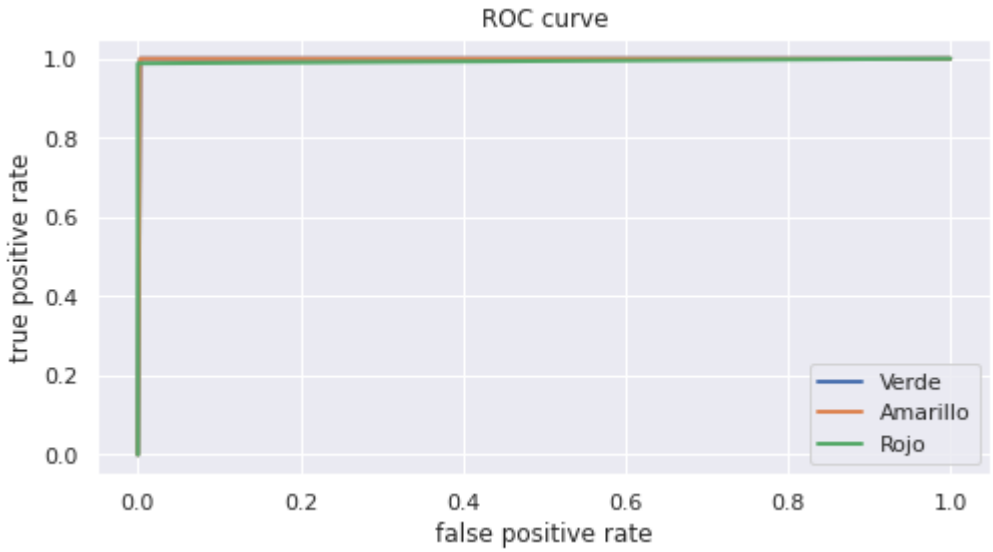

Donde igual obtenemos un 99% de area bajo la curva.

Visualiza los resultados del modelo o las predicciones a través de una matriz de confusión.

Generamos la matriz de confusión:

```
cm = confusion_matrix(ytest_cat, yhat)
```

La visualizamos:

```
df_cm = pd.DataFrame(cm, index = ['Verde','Amarillo','Rojo'], columns = ['Verde','Amarillo','
plt.figure(figsize = (5,5))
ax = sns.heatmap(df_cm, annot=True, fmt='d', cmap='OrRd', cbar=False)
ax.set(ylabel="Etiquetas Reales", xlabel="Etiquetas de Predicción")
```

```
[Text(21.499999999999996, 0.5, 'Etiquetas Reales'),
 Text(0.5, 21.5, 'Etiquetas de Predicción')]
```

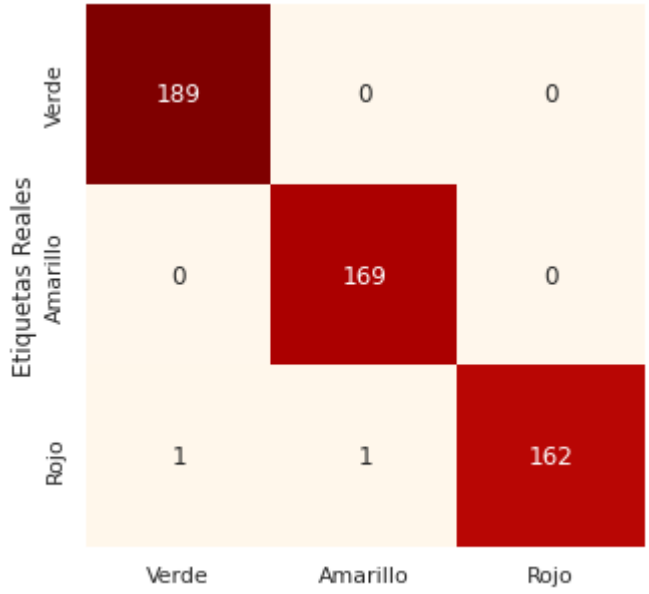

Y encontramos que el modelo consiguió predecir con un 99.6168% de exactitud los datos de prueba. Mientras que para la matriz de confusión:

- Errores de Clase Semáforo VERDE: FP=1, FN=0
- Errores de Clase Semáforo AMARILLO: FP=1, FN=0
- Errores de Clase Semáforo ROJO: FP=0, FN=2

Productos pagados de Colab - Cancela los contratos aquí